

Automatische Gehirntumor-Segmentierung aus MRT-Daten mit UNet

Annika Kassanke



PROBLEMDARSTELLUNG

Präzise Segmentierung von Gehirntumoren in MRT-Bildern ist entscheidend für die Diagnose, einen Behandlungsplan und die Therapieüberwachung. Allerdings ist die manuelle Segmentierung durch medizinisches Fachpersonal sehr zeitaufwendig, fehleranfällig und subjektiv.

MOTIVATION

Eine automatisierte Segmentierung mit einer 2D-UNet-Struktur kann diesen Prozess beschleunigen und die Genauigkeit erhöhen. Durch den Einsatz von DoubleConv-Blöcken werden lokale Zusammenhänge im Bild besser erfasst. In Kombination mit patch-basiertem Training und geeigneten Loss-Funktionen lassen sich selbst kleine Tumorregionen zuverlässig erkennen, was für die Diagnose, Therapieplanung und Verlaufskontrolle von großer Bedeutung ist.

RELEVANTE ARBEITEN

Lefkovits et al.^[1] untersuchen klassische 2D-UNet-Strukturen, die DoubleConv-Blöcke verwenden und mit einem patch-basiertem Trainingsdatensatz arbeiten. Dies führt zu einer deutlich verbesserten Erkennung kleiner Tumorregionen.

Sudre et al.^[2] zeigen zudem, dass der Dice Loss die Überlappung von Vorhersage und Ground Truth optimiert und dass die Kombination mit dem BCE Loss das Training stabilisieren kann.

REFERENZEN

[1] Lefkovits, S., Kovács, A., & Szabó, T. (2022). *U-Net architecture variants for brain tumor segmentation*. Acta Universitatis Sapientiae, Informatica, 14(1), 23–38.

DOI: 10.2478/ausi-2022-0004

[2] Sudre, C. H., Li, W., Vercauteren, T., Ourselin, S., & Jorge Cardoso, M. (2017). *Generalised Dice overlap as a deep learning loss function for highly unbalanced segmentations*. In Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (pp. 240–248). Springer.

DOI: 10.1007/978-3-319-67558-9_28


[3] Jadon, S. (2020). *A survey of loss functions for semantic segmentation*. 2020 IEEE Conference on Computational Intelligence in Bioinformatics and Computational Biology (CIBCB), 1–7.

DOI: 10.1109/CIBCB48159.2020.9277638

METHODE

Datengrundlage und Patch-Extraktion

MRT-Datensatz mit zugehörigen binären Tumormasken (BraTS2020, insg. 369 Volumen mit je 154 Slices)




Patch-Extraktion

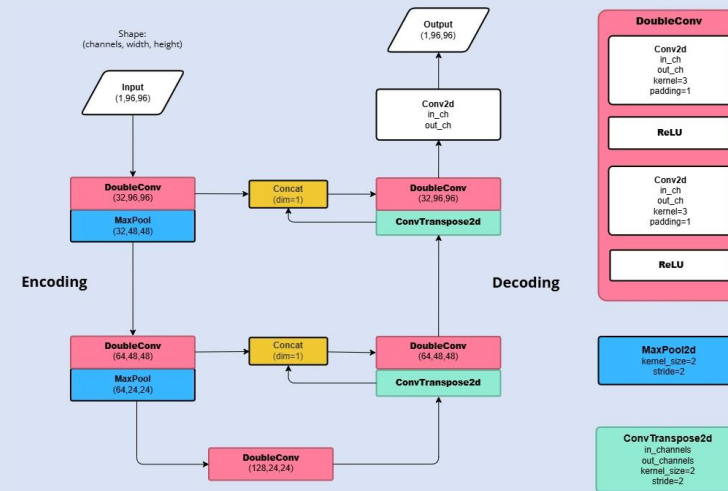
Stride: 48

klassenbalanciert:
Tumor (Anteil > 1%) vs.
Background mit je 2500
Patches

zufällige Aufteilung:
80% Trainings- und 20%
Validierungsdaten



Netzwerkarchitektur – 2D-UNet-Architektur



Trainingsprotokoll

mit 45 Epochen, bei einer Batchgröße von 8 → 500 Mini-Batch-Updates der Gewichte pro Epoche.

Zur Optimierung der Netzwerkgewichte wurde der Adam-Optimierer mit einer Lernrate von 1×10^{-4} verwendet.

Validierung

mit dem Dice-Score für das UNets mit beiden Loss-Funktionen. Dice Loss und die Kombination aus BCE und Dice Loss.

Loss-Funktionen [3]

Dice-Score

$$DSC = \frac{2 \cdot |X \cap Y| + \epsilon}{|X| + |Y| + \epsilon}$$

$|X \cap Y|$ - Überlappungsbereich
Anzahl der Pixel, die in beiden
Masken (Ground Truth und
Prediction) eine 1 haben
 $|X| + |Y|$ - Gesamtzahl der Pixel mit 1
in jeder einzelnen Maske
 ϵ - Korrekturwert mit 10^{-6} für leere
Masken

Dice Loss

$$\mathcal{L}_{Dice} = 1 - Dice$$

optimiert die Überlappung
der Segmentierungsflächen

Binary Cross Entropy Loss

$$\mathcal{L}_{BCE} = -\frac{1}{N} \sum_{i=1}^N (y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i))$$

$\hat{y}$ - vorhergesagte Wahrscheinlichkeit
 y - tatsächliche Wahrscheinlichkeit
misst gemittelte pixelweisen
Klassifikationsfehler

Kombination BCE + Dice Loss

$$\mathcal{L}_{BCE+Dice} = \mathcal{L}_{BCE} + \mathcal{L}_{Dice}$$


ERGEBNISSE

Qualitativ – illustrativer Trainingszustand (BCE + Dice Loss)


Zufällig ausgewähltes Validation-Patch
(1x96x96) wird durch aktuelles Netz der
Epoche geschickt.




Epoche 2/45



Epoche 44/45



Quantitativ – Vergleich der Dice-Scores



genutzte Loss-Funktionen	Dice-Score (45 Epochen)
Dice Loss	0,8723
BCE + Dice Loss	0,9070

Der Dice Loss optimiert direkt die Überlappung zwischen vorhergesagter und Ground-Truth-Tumormaske, dabei liegt der Fokus auf der Tumorregion. Der Dice Loss ist somit sehr empfindlich bei kleinen/fehlenden Tumoren im Batch. Wird der Dice Loss mit der BCE zur pixelweisen Klassifikation von Tumor und Hintergrund kombiniert, ergeben sich gleichmäßigere Gradienten, ein stabilerer Trainingsverlauf und ein höherer Dice-Score.

Limitationen

Das Modell verarbeitet einzelne 2D-Patches und berücksichtigt keine räumlichen Informationen aus benachbarten MRT-Slices (kein 3D-Kontext). Das verwendete 50/50-Sampling von Tumor- und Hintergrund-Patches reduziert zwar das Klassenungleichgewicht während des Trainings, entspricht jedoch nicht der tatsächlichen klinischen Datenverteilung. Zudem wird ausschließlich die T1-MRT-Modalität verwendet anstatt der multimodalen Daten (T1CE, T2, FLAIR). Darüber hinaus könnte das Modell noch mit residualen Verbindungen und einem Attention-Mechanismus verbessern.